2020 年 9 月 第 9 期
Vol. 41 No. 9 2020

一种基于改进条件生成式对抗网络的人脸表情生成方法

王先先,李菲菲,陈 虬

(上海理工大学 光电信息与计算机工程学院,上海 200093)
E-mail:xxwang2017@163.com

摘 要:人脸表情生成一直都是一项具有挑战性的工作. 现有的方法通常将深度生成网络和面部特征相结合来完成这项任务. 然而,同一张人脸的面部表情不仅微妙,而且数不胜数. 如何在保持人脸身份信息不变的前提下,利用人脸特征准确地生成目标表情仍然是一个有待解决的问题. 本文利用人脸特征点来描述不同的表情形状,并以此作为生成目标表情的引导条件. 我们通过对 Pix2Pix 模型结构的改进,实现了高质量人脸表情的生成. 同时,为了引导连续人脸表情的生成,我们使用变分自动编码器对人脸形状进行控制. 在两个公开的数据集 CK +、Oulu-CASIA 上,我们评估并验证了模型在任意人脸表情转换、人脸表情移除、人脸表情生成、连续人脸表情生成等任务上的可行性和有效性.

关 键 词:人脸表情生成;条件生成对抗网络;表情形状控制器;变分自动编码器
中图分类号:TP391 文献标识码:A 文 章 编 号:1000-1220(2020)09-1987-06

Facial Expression Generation Method Based on Enhanced Conditional Generative Adversarial Networks

WANG Xian-xian, LI Fei-fei, CHEN Qiu
(School of Optical-Electrical and Computer Engineering, University of Shanghai for Science and Technology, Shanghai 200093, China)

Abstract: Facial expression generation has long been a challenging job. Existing methods often combine deep generative networks with facial features to complete this task. However, the facial expressions of the same face are not only subtle, but numerous. How to utilize facial features to exactly generate target expression while keep facial identity invariant is still an open problem. In this paper, we explore using facial landmarks to describe different expression shapes, which are further taken as the guiding conditions to synthesize target expression. We base this conditional expression generative model on Pix2Pix GANs and improve its performance in generating high-quality image by elaborately designing the networks' architecture. Meanwhile, in order to guide the generating of continuous facial expressions, we build a facial shape controller to generate a series of shapes between referential expression and target expression. We evaluated and verified the feasibility and effectiveness of the proposed model for tasks such as arbitrary face expression transformation, face expression removal, face expression generation, and continuous face expression generation on two public datasets (Oulu-CASIA and CK +).

Key words: facial expression generation; CGANs; expression shape controller; β-VAE

1 引 言

人脸表情生成的目标在于生成表情丰富而纹理清晰的不同人脸,其可广泛应用于表情分类、辅助驾驶、人机交互等多个领域. 因此,表情生成一直以来都是计算机视觉和图像处理领域的研究热点. 传统方法通常使用计算机图形学方法进行建模来实现人脸表情的生成. Lin 等[2]提出将人脸划分成若干几何区域,然后将参考人脸表情的纹理映射到目标表情的几何区域中. Zhang 等[3]提出根据不同表情之间特征点的变换对人脸进行表情变形. 这些方法虽然在一定程度上实现了人脸表情的生成,然而生成的目标表情一方面数量有限(取决于几何区域的划分),另一方面并不自然,缺乏真实性,很难得到进一步利用.

近年来,生成式对抗网络[4]在图像生成方面展现出了强大的拟合能力. 研究人员利用生成对抗网络可以生成高质量纹理细节图像的特点来实现人脸表情的生成. 本文利用条件生成对抗网络模型,以目标人脸表情形状为条件,任意人脸表情为参考图像,实现人脸表情的生成. 主要贡献可以归纳如下:

1)以人脸特征点位置为不同的表情形状进行建模,作为目标表情生成的引导条件,并对 Pix2Pix 模型[13]的网络结构进行改进,以提高其在人脸表情生成方面的性能. 解决当前人脸表情生成模型网络结构复杂,参考表情和目标表情之间不能直接相互转换的问题.

2)利用训练好的变分自动编码器[14]作为人脸表情形状控制器. 通过该控制器可以生成一系列具有视觉语义变化的、可解耦的表情形状. 将形状控制器和表情生成模型相结合,可

收稿日期:2019-10-12 收修改稿日期:2019-12-06 基金项目:上海市高校特聘教授(东方学者)岗位计划项目(ES2015XX)资助. 作者简介:王先先,男,1990 年生,硕士研究生,研究方向为图像处理与模式识别;李菲菲,女,1970 年生,博士,教授,研究方向为多媒体信息处理、图像处理与模式识别、信息检索等;陈 虬,男,1972 年生,博士,教授,研究方向为图像处理与模式识别、计算机视觉、信息检索等.

(C)1994-2020 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

以生成连续的、具有视觉语义变化的人脸表情.

2 相关工作

2.1 图像生成模型

近年来,深度神经网络在图像生成领域取得了很大的进展. 一般来说,通常有两类常用的生成模型用于图像生成. 一类基于 VAE[1] (variational auto-encoder) 的生成模型是一种概率统计模型. 它主要由用于推断输入图像统计信息的编码网络和用于重构输入图像的解码网络组成. 这类生成模型具有训练稳定、收敛速度快等一系列优点. 然而,由于 VAE 模型优化的目标函数是对数似然函数的下界,生成的图像整体上看起来较为模糊. 另一类基于 GANs[4] (generative adversarial networks) 的图像生成模型则是通过生成器和判别器之间的对抗学习,隐式地捕获真实图像的概率分布. 通过对抗性的训练,GANs 类模型可以生成更加清晰、逼真的图像. 然而原始的 GANs 模型仍然存在许多显著的缺陷[27],如模式崩溃和训练不稳定等. 研究人员[22,23]提出了一些有效的方法来稳定训练过程、提高生成图像的质量. 此外,为了使得生成的图像具有某些期望的属性,研究人员[15,25]提出使用条件 GANs 对生成的图像进行约束. 比如引入类标签之类的辅助信息来指导手写数字图像的生成. 目前为止,基于 CGANs 的模型已经广泛应用于超分辨率图像生成[10,11,26]、图像风格转换[12,18]、图像修复[20]等领域. 由于对抗网络在生成图像方面的优异表现,我们同样采用对抗网络来完成目标人脸表情的生成.

2.2 人脸生成模型

利用深度神经网络生成人脸表情的研究工作大致可分为两类:一类是研究人员使用离散的面部属性来进行人脸生成. Yan 等[9]提出将性别、表情类别、头发颜色等信息编码到条件 VAE 模型的瓶颈层中,从而生成具有多样化外观的人脸. Choi 等[17]将不同的表情状态(如生气、开心)划为不同的域,并提出 StarGAN 实现几种典型表情之间的相互转化. StarGAN 的判别器不仅需要判断生成图像的真伪,还需要判断它来自哪个域. 虽然这些方法可以生成高质量的人脸表情图像,然而编码后的离散人脸属性并不足以描述丰富的面部表情. 例如,开心的表情可能对应于嘴巴大小不同的各种笑脸. 为了解决这个问题,研究人员探索如何将连续的辅助信息整合到生成模型中. Zhou 等[8]提出可以将人脸身份和表情信息相分离的 CDAAE 模型. 在 CDAAE 中,给定参考人脸表情,通过改变表示不同表情强度的 FAU(facial action unit)标签可以生成同一个人的多种表情. GAGAN[5]将人脸表情形状和 GANs 相结合,使得生成的人脸表情真实、自然并且具有指定的表情形状. 然而,由于 GAGAN 本身的半监督性,其并不能对生成人脸的身份信息进行任何控制. 有关连续人脸表情的生成,Qiao 等[7]提出利用人脸特征点直接对两个不同的表情形状进行线性插值,然后使用全连接网络将这些形状压缩成一维的编码向量,最后将编码向量输入到对抗网络中进而完成连续表情的生成. Song 等[6]同样以人脸特征点为可控条件并提出 G2-GAN 模型用于面部表情合成. G2-GAN 通过两个生成网络分别实现表情的移除和生成,进而实现任意表情的转换. 在本文中,我们从现有的方法出发,提出了一种简单而有效的模型来实现目标人脸表情的生成. 为了对不同的表情形状进行建模,我们使用像素宽度为 1 的折线段来连接人脸不同部位的特征点. 该模型将参考表情与人脸形状控制器相结合,既可以直接生成目标表情而不用中性人脸表情作为中间的转换媒介,也可以实现连续人脸表情的生成,同时保持人脸身份信息的一致性.

3 改进的条件人脸表情生成模型

3.1 条件人脸表情生成模型

3.1.1 模型网络结构

除了表情上的差异,目标图像和参考图像应该共享同一张人脸的大部分纹理信息. 为了在保持人脸身份信息不变的条件下,模型能够根据表情形状 g 生成目标表情,我们采用改进的Pix2Pix[13]模型作为生成器,如图1所示. 该模块主要由

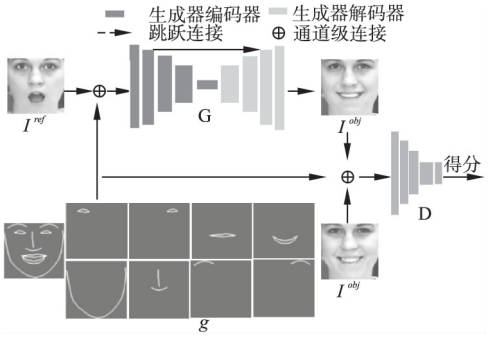

图 1 人脸表情生成模型的整体结构

Fig. 1 Overall structure of facial expression generation model

两个子网络组成:编码网络 G_{Enc} 和解码网络 G_{Dec}. 目标表情形状 g 与参考图像 I^{ref} 进行连接后共同作为 U-Net 结构的生成器的输入. 生成器的编码网络 G_{enc} 从输入的图像中提取身份、纹理等高级特征到瓶颈层. 生成器的解码网络 G_{dec} 则负责融合来自 U-Net 路径的高级特征和来自 skip-connection 路径的低级特性以生成目标人脸表情. 为了提高了生成图像的质量,我们在 Pix2Pix 模型的基础上做了以下几个方面的修改:

1) 我们使用 WGAN-GP[24] 代替原始的 GANs. 原始 GANs 判别器对输入的判别图像只作真假的二值判断,而 WGAN-GP 采用 wasserstein 距离度量目标图像与生成图像分布之间距离. 与原始 GAN 相比,它可以为生成器提供更好的优化方向.

2) 对于 Pix2Pix 模型而言,生成器的编码网络 G_{Enc} 和解码网络 G_{Dec} 镜像层之间存在很多跳跃连接. 而在实验中,我们发现镜像层之间过多的跳跃连接会导致生成器的过拟合,即在训练集上生成目标表情的性能要优于测试集. 为此,我们减少冗余的连接,只保留一条跳跃连接.

3) 为了简化模型的组成结构,除了判别器的最后一层外,生成器和判别器的所有卷积层均采用 3×3 大小的卷积核.

3.1.2 对抗损失

对抗网络最重要的特点是通过生成器和判别器之间的对抗性学习来训练网络模型,使得生成器能够生成真实且自然的图像. 在本文中,多通道的表情形状图像 g 和参考人脸表情

(C)1994-2020 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

I^{ref}成对的作为生成器的输入. 根据 Pix2Pix 模型和 WGAN-GP 模型,我们的对抗网络的损失函数如下:

$$L_{Gen} = -E_{I^{ref},g\sim P(I^{ref},g)}D(G(I^{ref},g),g) \tag{1}$$

$$L_{Dis} = -E_{I^{obj},g\sim P(I^{obj},g)}D(I^{obj},g) + E_{I^{ref},g\sim P(I^{ref},g)} D(G(I^{ref},g),g) + \lambda E_{I',g\sim P(I',g)}(\|\nabla_{I'}D(I',g)\|_2 - 1)^2 \tag{2}$$

其中 L_{Gen}和 L_{Dis}分别表示生成器和判别器的对抗损失函数,I^{obj}表示目标人脸表情,$E_{I',g\sim P(I',g)}(\|\nabla_{I'}D(I',g)\|_2 - 1)^2$ 表示 WGAN-GP 网络的梯度惩罚项.

3.1.3　像素级损失

优化对抗损失函数使得生成的图像看起来更真实,但这还不够. 对于人脸表情变换的任务,我们还希望生成表情 I^{gen}和目标表情 I^{obj}尽可能地一致. Isola 等[13] 工作表明优化生成图像和目标图像之间的 L_1 范数可以有效地缓解由 L_2 范数所引起的模糊结果. 因此,我们使用 L_1 范数来计算生成图像 I^{gen}和目标图像 I^{obj}之间的像素级的差异:

$$L_{Pix} = \|I^{obj} - I^{gen}\|_1 = \|I^{obj} - G(I^{ref},g)\|_1 \tag{3}$$

3.1.4　感知损失

优化像素损失一方面有助于保持生成图像和目标图像面部轮廓特征一致. 然而,另一方面也会导致生成的图像在纹理丰富的区域存在一定程度的模糊. Johnson[12] 等提出的感知损失在超分辨率图像生成、风格转换等任务中得到广泛的应用,表明了它在提取纹理特征方面的有效性. 因而我们采用预先训练好的 VGG-FACE[28] 分别提取生成表情和目标表情的纹理特征. 通过优化感知损失函数,使得二者在特征空间保持一致性:

$$L_{Perp} = \|F(I^{obj}) - F(I^{gen})\|_1 \tag{4}$$

其中 F 表示训练好的 VGG-FACE 模型.

综合上述,模型总的损失函数如下所示:

$$L_{Total} = L_{Dis} + L_{Gen} + \lambda_1 L_{Pix} + \lambda_2 L_{Perp} \tag{5}$$

3.2　表情形状控制模型

大多数情况下,我们只有有限数量的人脸表情用于转换. 事实上,我们几乎也不太可能通过检测或标注的方法得到目标人脸表情的形状. 因此,设计一种控制器来生成各种表情形状,进而引导目标表情的生成是一项非常必要的工作. 已有的工作[5] 采用 PCA(principle component analysis)的方法来实现. 这些方法先将人脸形状的一维向量压缩到低维空间进行编码,然后通过改变编码向量的值并解码至高维空间来生成新的形状. 然而,基于 PCA 的方法本质上是一种线性编码,无法捕捉输入表情形状特征之间的非线性关系. 此外,编码向量的某一维度与表情形状可分解的视觉属性之间只存在弱关联性. 为解决这一问题,我们使用 β-VAE[14] 作为表情形状控制器,如图 2 所示. 与标准 VAE 的结构相同,它也是由编码器网络和解码器网络组成,其目标函数如下:

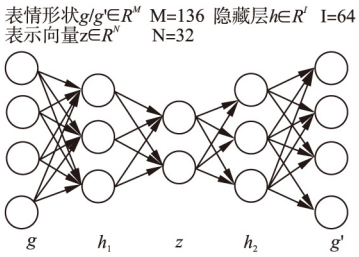

图 2　表情形状控制器的网络结构

Fig. 2　Networks structure of expression shape controller

$$L_{Ctrl} = E_{q_\phi(z|g)}\log p_\theta(g'|z) - \beta KL(q_\phi(z|g)\|p_\theta(z)) \tag{6}$$

其中第一项 $\log p_\theta(g'|z)$ 表示重建形状 g'的最大对数似然函数,θ 为解码网络. 通过优化这一项,形状控制器的解码网络可以从条件编码向量 $z|g$ 中重构出人脸形状 g. 第二项 $KL(q_\phi(z|g)\|p_\theta(z))$为正则项,$p_\theta(z)$是均值为 0,协方差为 0,方差为 1 的先验多元高斯分布. 编码网络 ϕ 将输入的表情形状 g 进行压缩编码. 通过优化这两个分布 Kull-back Leibler 距离,条件编码向量 $z|g$ 的每一维度都具有视觉特征可分解的解释性. 与标准 VAE 不同的是,可调权重系数 β 负责平衡表情形状 g 的重建精度和相应的表示向量 $z|g$ 中每个维度的可解释性. 在这项工作中我们将超参数 β 的值设置为 10 的表示向量中每个维度的可解释性. 在这项工作中我们将超参数的值设置为 10.

4　实验结果和分析

在本节中,我们评估了该方法在生成目标人脸表情方面的性能. 首先,我们介绍了两种常用的表情数据集及其预处理方法和训练设置细节. 然后,我们在任意人脸表情转换、人脸表情生成、人脸表情移除、连续人脸表情生成等任务上展示了生成图像的可视化结果. 此外,对于表情生成和表情移除任务,我们选取 PSNR(peak signal to noise ratio)和 SSIM(structural similarity index)指标来评估生成图像与目标图像之间的差距,以此证明该方法的有效性.

4.1　数据集及预处理

4.1.1　CK+数据集

CK+数据集[16] 是由来自 123 个人共计 593 个面部表情序列组成. 每个人都包含几种典型的表情序列图像,这些表情序列以中性的表情开始,以某种最强烈的表情结束. 除了少数彩色的表情序列外,CK+数据集中的图像大多为灰度图像. 我们将这些彩色图像转换成灰度图像,并按照 8∶2 的比例随机地选择 99 个人的表情序列作为训练集,其余 24 个人的表情序列作为测试集. 此外,我们直接使用该数据集提供的 68 个人脸表情特征点作为表情形状.

4.1.2　Oulu-CASIA 数据集

Oulu-CASIA 数据集[21] 是由 80 个人的 6 种不同的表情序列组成. 这些表情序列由近红外和可见光两种摄像机分别在三种不同的光照条件下(暗光、弱光、强光)获得. 我们只选取可见光摄像机在强光照下拍摄的序列作为实验数据. 实验总计使用了 480 个表情序列,其中前 50 个和后 30 个人的表情序列分别在在芬兰和中国获得. 为了保证样本的平衡性,我们按照 8∶2 的比例随机选取一个由 40 个芬兰人和 24 个中国人组成的训练集,以及一个由 10 个芬兰人和 6 个中国人组成的测试集. 此外,该数据集并没有提供标注好的特征点,我们使用 FAN 模型[19] 来进行提取.

4.1.3　数据集预处理

同一表情序列中相邻图像往往只存在细微差异. 然而我们的方法需要任意抽取一对不同的表情作为模型输入. 为了减少不必要的训练时间,我们每 3 帧对原序列进行采样,进而

(C)1994-2020 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

构建一个相对小的训练集. 原训练集中所有图像可以在 3 个 epoch 内训练完毕. 实验中,根据人眼位置进行人脸对齐,然后裁剪出具有 5 像素边距的图像,最后将裁剪后的尺寸缩放成 144 × 144. 同时,对特征点坐标进行仿射、缩放等操作,使其与处理后的人脸图像保持一致. 训练时,我们使用像素宽度为 1 的折线来连接不同部位的特征点,以构建一个多通道的表情形状图像. 此外,表情图像的值归一化为[- 1,1],多通道的表情形状的值设置为 1. 在训练形状控制器时,将特征点的坐标值进行均值为 0,方差为 1 的归一化.

4.1.4 训练细节

训练时使用 ADAM 优化器进行优化;批处理大小设为 4;判别器和生成器的学习率分别设置为 0.0002 和 0.0001;损失函数的权重参数 λ_1 和 λ_2 分别设置为 10 和 1;训练时采用随机水平翻转和随机裁剪的方法进行数据增强;测试阶段只使用中心裁剪,裁剪尺寸为 128 × 128 大小.

4.2 实验结果及分析

4.2.1 任意人脸表情转换

人脸表情转换是指实现任意参考表情和目标表情之间的转换. G2-GAN 采取的方法是首先使用表情移除模型将参考表情转换成中性表情,然后使用表情生成模型将中性表情转换成目标表情. 而在我们的模型中,中性表情并不作为完成转换的必要中间媒介. 实验结果显示在图 3 和图 4 中. 对于每个人的三行表情而言,第一列为参考表情 I^{ref},第二列和第三列分别为目标表情 I^{obj} 和相应的生成表情 I^{gen}. 可以看到,转换后的人脸表情和目标表情既具有相同的身份信息也具有相同表情形状,所述模型可以很好地完成目标人脸表情的转换工作. 然而,由于生成的表情图像同时受到参考表情 I^{ref} 和目标表情

图 3 Oulu 数据集上的人脸表情转换

Fig. 3 Facial expression transform on Oulu dataset

图 4 CK + 数据集上的人脸表情转换

Fig. 4 Facial expression transform on ck + dataset

形状 g 共同的作用结果. 因此,生成表情和目标表情之间存在细微的差别. 此外,在 Oulu-CASIA 数据集上的实验结果表明,生成的图像不受表情形状以外因素的影响(如眼镜和背景等). 与 Oulu-CASIA 人脸数据集相比,CK + 人脸数据集中的图像具有更高的分辨率,这也合理地解释了图 4 中所生成的人脸表情在纹理更丰富的嘴巴和眼睛等区域具有更加清晰的细节特征.

4.2.2 人脸表情移除和生成

人脸表情移除是指将具有某种表情的人脸转换成不含任何表情的中性人脸,反之则称为表情生成. 对于表情移除,我们使用各表情序列中的第一帧作为目标表情 I^{obj}(中性表情),而其余各帧依次作为参考表情 I^{ref}. 对于表情生成,我们使用各表情序列的第一帧作为参考表情 I^{ref}(中性表情),其余各帧依次作为目标表情 I^{obj}. 我们分别在 CK + 和 Oulu 数据集上进行表情移除和表情生成实验. 在测试集中,我们随机地从生成的表情序列中为每个人选取 4 张生成的人脸表情,并将它们与真实图像相比较,结果如图 5 和图 6 所示. 对于图中每个人的三行表情序列而言,第一行表情为真实图像,第二行为

图 5 Oulu 数据集上人脸表情生成和移除

Fig. 5 Facial expression synthesis and remove on Oulu dataset

图 6 CK + 数据集上人脸表情的生成和移除

Fig. 6 Facial expression synthesis and remove on ck + dataset

表情生成图像,第三行为表情移除图像. 可以看到,表情生成的图像几乎和真实图像具有相同形状,而所有表情移除的图像几乎一致. 此外,我们使用PSNR和SSIM指标分别定量地评测了表情生成和表情移除任务中生成的图像与真实图像之间的差异. 同时,为了表明改进方法的有效性,我们对不同的

表 1 表情移除和表情生成实验在不同模型配置下定量评测结果

Table 1 Quantitative results of different model configurations for expression remove and synthesis experiments

数据集	模型	表情移除		表情生成	
		PSNR	SSIM	PSNR	SSIM
CK + /Oulu-CASIA	A	26.332/26.781	0.860/0.860	25.937/26.252	0.849/0.846
	B	24.729/24.653	0.802/0.793	24.356/24.279	0.791/0.785
	C	24.382/27.272	0.805/0.852	24.114/26.958	0.797/0.844
	D	23.265/24.361	0.797/0.809	22.834/23.952	0.778/0.791

(C)1994-2020 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

模型结构做了对比试验,具体结果如表 1 所示. 其中配置 A 为所改进的模型;B 为 Pix2Pix 模型;C 和 A 一致,但使用原始 GANs;D 和 A 一致,但没有跳跃连接. 评测结果表明我们的改进方法在两个数据集上均可以显著的提高生成图像的质量.

4.2.3　连续人脸表情生成

大多数情况下我们只有少数人脸表情. 然而,我们的目标不仅是生成从未见过的人脸表情,我们还想从语义的角度控制这些表情的生成. 比如,通过控制表情形状控制器生成只有嘴巴大小改变的表情形状,进而生成相对应的人脸表情. 具体方法如下:首先使用训练好的形状控制器,将一个中性的表情形状从形状空间压缩到低维的表示空间. 然后通过对指定的维度值进行线性变换,再将其映射回形状空间,得到一组具有共同语义变化的表情形状. 最后,将这组形状输入到条件人脸表情生成模型的生成器中,生成一系列语义上可连续变化的人脸表情. 在图7中,我们展示了该方法在CK + 数据集上的

图 7　CK + 数据集上的连续人脸表情生成

Fig. 7　Continuous expression synthesis on ck + dataset

实验结果. 每对序列的第一行是由形状控制器生成的一系列连续的人脸形状,第二行是由中性人脸作为参考表情生成的对应表情. 三行形状序列分别是通过线性改变低维表示向量的第 1 维、第 2 维、第 21 维值而产生的. 我们可以看到,人脸形状低维表示向量的维度与解耦的视觉特征有着密切的语义关系. 例如,表示向量的第 2 维控制眼睛的大小,第 21 维控制嘴巴的长度,而所生成的表情与人脸形状的变化基本上是一致的. 此外,我们还可以完成人脸表情插值任务. 通过对表示向量空间中任意两个人脸形状之间的线性插值,可以得到一系列的引导形状. 这些形状可以帮助我们在参考表情和目标表情之间生成另一种类型的连续人脸表情. 需要特别指出的是,所有这些连续生成的人脸表情均没有对应的真实图像.

5　总　结

在这项工作中,我们提出了一种基于条件生成对抗网络的模型来实现目标人脸表情生成的方法. 相比于 FAU 编码或离散表情类别标签,人脸特征点是对丰富的人脸表情进行建模的一个理想选择. 利用特征点表示表情形状,我们的模型能够生成大量的、纹理细节清晰的,同时保持身份信息不变的表情. 本文中,我们使用所提出的方法实现了表情转换、表情移除、表情合成等多个任务. 此外,将基于 CGAN 的表情生成模型与所设计的形状控制器相结合,可以方便地在语义层次上实现连续人脸表情的生成. 然而,对于头部姿态发生变换的人脸表情生成任务,依然是本文后续工作的研究重点.

References:

[1] Kingma D P, Welling M. Auto-encoding variational Bayes[C]//International Conference on Learning Representation (ICLR), 2014.

[2] Lin Xue-yin, Hong Peng-yu. Facial expression image synthesis by using 2D model with uncoupled geometric and textural information [J]. Acta Electronics Sinica, 1998, 26(11): 124-127.

[3] Zhang Q S, Liu Z C, Guo B N, et al. Geometry-driven photorealistic facial expression synthesis[J]. IEEE Transactions on Visualization and Computer Graphics, 2005, 12(1): 48-60.

[4] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems, 2014: 2672-2680.

[5] Kossaifi J, Tran L, Panagakis Y, et al. GAGAN: geometry-aware generative adversarial networks[C]//IEEE Conference on Computer Vision and Pattern Recognition, 2018: 878-887.

[6] Song L X, Lu Z H, He R, et al. Geometry guided adversarial facial expression synthesis[C]//Proceedings of the 26th ACM International Conference on Multimedia, 2018: 627-635.

[7] Qiao F C, Yao N M, Jiao Z R, et al. Emotional facial expression transfer from a single image viagenerative adversarial nets[J]. Computer Animation and Virtual Worlds, 2018, 29(3-4): e1819.

[8] Zhou Y Q, Shi B E. Photorealistic facial expression synthesis by the conditional difference adversarial autoencoder[C]//Seventh International Conference on Affective Computing and Intelligent Interaction, 2017: 370-376.

[9] Yan X C, Yang J M, Sohn K, et al. Attribute2 image: conditional image generation from visual attributes[C]//European Conference on Computer Vision(ECCV), 2016: 776-791.

[10] Wang T C, Liu M Y, Zhu J Y, et al. High-resolution image synthesis and semantic manipulation with conditional GANs[C]//IEEE Conference on Computer Vision and Pattern Recognition(CVPR), 2018: 8798-8807.

[11] Wang X T, Yu K, Wu S X, et al. ESRGAN: enhanced super-resolution generative adversarial networks[C]//European Conference on Computer Vision(ECCV), 2018: 63-79.

[12] Johnson J, Alahi A, Li F F. Perceptual losses for real-time style transfer and super-resolution[C]//European Conference on Computer Vision(ECCV), 2016: 694-711.

[13] Isola P, Zhu J Y, Zhou T H, et al. Image-to-image translation with conditional adversarial networks[C]//Computer Vision and Pattern Recognition(CVPR), 2017: 5967-5976.

[14] Higgins I, Matthey L, Pal A, et al. beta-VAE: learning basic visual concepts with a constrained variational framework[C]//International Conference on Learning Representations(ICLR), 2017.

[15] Mirza M, Osindero S. Conditional generative adversarial nets[EB/OL]. https://arxiv.org/abs/1411.1784, 2014, 11.

[16] Lucey P, Cohn J F, Kanade T, et al. The extended cohn-kanade dataset(CK +): a complete dataset for action unit and emotion-specified expression[C]//IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops(CVPRW), 2010: 94-101.

(C)1994-2020 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[17] Choi Y, Choi M, Kim M, et al. StarGAN: unified generative adversarial networks for multi-domain image-to-image translation[C]// IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8789-8797.
[18] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//IEEE International Conference on Computer Vision, 2017: 2242-2251.
[19] Bulat A, Tzimiropoulos G. How far are we from solving the 2D & 3D face alignment problem? (and a dataset of 230,000 3D facial landmarks)[C]//IEEE International Conference on Computer Vision (ICCV), 2017: 1021-1030.
[20] Yeh R A, Chen C, Lim T Y, et al. Semantic image inpainting with deep generative models[C]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 6882-6980.
[21] Zhao G Y, Huang X H, Taini M, et al. Facial expression recognition from near-infrared videos[J]. Image and Vision Computing, 2011, 29(9): 607-619.
[22] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[C]//International Conference on Learning Representations (ICLR), 2016.
[23] Arjovsky M, Chintala S, Bottou L, et al. Wasserstein generative adversarial networks [C]//International Conference on Machine Learning, 2017: 214-223.
[24] Gulrajani I, Ahmed F, Arjovsky M, et al. Improved training of wasserstein GANs [C]//Advances in Neural Information Processing Systems (NIPS), 2017: 5767-5777.
[25] Chen X, Duan Y, Houthooft R, et al. Infogan: interpretable representation learning by information maximizing generative adversarial nets [C]//Advances in Neural Information Processing Systems, 2016: 2172-2180.
[26] Ledig C, Theis L, Huszar F, et al. Photo-realistic single image super-resolution using a generative adversarial network [C]//Computer Vision and Pattern Recognition, 2017: 105-114.
[27] Arjovsky M, Bottou L. Towards principled methods for training generative adversarial networks [C]//International Conference on Learning Representations, 2017.
[28] Cao Q, Shen L, Xie W D, et al. VGGFace2: a dataset for recognising faces across pose and age[C]//IEEE International Conference on Automatic Face and Gesture Recognition and Workshops, 2018: 67-74.

附中文参考文献:

[2] 林学闾, 洪鹏宇. 基于 2D 几何与纹理信息分离模型的表情分析与合成[J]. 电子学报, 1998, 26(11): 124-127.

本刊检索与收录

国内

中文核心期刊
中国学术期刊文摘(中英文版)收录
中国科学引文数据库(CSCD)来源期刊
中国科技论文统计源期刊
中国期刊全文数据库(CJFD)收录期刊
中国科技期刊精品数据库收录期刊
中国学术期刊综合评价数据库(CAJCED)收录期刊
中国核心期刊(遴选)数据库收录期刊
中文科技期刊数据库收录期刊

国际

英国《科学文摘》(INSPEC)
荷兰《文摘与引文数据库》(SCOPUS)
俄罗斯《文摘杂志》(AJ, VINITI)
美国《剑桥科学文摘(自然科学)》CSA(NS); Cambridge Scientific Abstracts(Natural Science)
美国《剑桥科学文摘》CSA(T); Cambridge Scientific Abstracts(Technology)
美国《乌利希期刊指南》UPD(Ulrich's Periodicals Directory)
日本《日本科学技术振兴机构中国文献数据库》(JST, China)
波兰《哥白尼索引》(IC, Index of Copurnicus)

(C)1994-2020 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net