

## 第七章 特征值问题的迭代解法

当矩阵规模很大时, 计算其所有的特征值和特征向量是非常困难的. 而在实际应用中, 我们通常也只对其中的某些特征值和特征向量感兴趣, 因此也没必要计算所有的特征值和特征向量.

本章讨论计算部分特征值和特征值向量的迭代解法. 这些算法的存储量要远小于  $O(n^2)$ , 运算量也远小于  $O(n^3)$ .

## 7.1 投影算法

最简单的特征值问题就是仅仅计算一个特征值, 如计算模最大的特征值. 这时我们可以使用幂迭代算法.

---

### 算法 7.1 幂迭代: 计算最大特征值

---

```

1: Given  $x^{(0)}$ 
2: for  $i = 1, 2, \dots$ , until converge do
3:    $y^{(i)} = Ax^{(i-1)}$ 
4:    $x^{(i)} = y^{(i)} / \|y^{(i)}\|_2$ 
5: end for

```

---

幂迭代所产生的迭代向量  $x^{(0)}, x^{(1)}, \dots, x^{(m-1)}$  生成一个 Krylov 子空间

$$\mathcal{K}_m(A, x^{(0)}) = \text{span} \left\{ x^{(0)}, Ax^{(0)}, \dots, A^{m-1}x^{(0)} \right\}.$$

在幂迭代中, 我们取  $x^{(m-1)}$  为近似特征向量. 显然, 如果我们在  $\mathcal{K}_m(A, x^{(0)})$  中找出“最佳”的近似特征向量, 则收敛速度就可能会大大加快.

下面我们讨论如何在  $\mathcal{K}_m = \mathcal{K}_m(A, x^{(0)})$  中寻找“最佳”的近似特征向量. 设  $A \in \mathbb{R}^{n \times n}$ , 并设  $\mathcal{K}_m$  和  $\mathcal{L}_m$  是  $\mathbb{R}^n$  的两个  $m$  维子空间. 投影算法就是在寻找  $A$  的近似特征对  $(\tilde{\lambda}, \tilde{x})$ , 满足下面的 Petrov-Galerkin 条件

$$\text{find } \tilde{\lambda} \in \mathbb{C} \text{ and } \tilde{x} \in \mathcal{K}_m \quad \text{such that} \quad A\tilde{x} - \tilde{\lambda}\tilde{x} \perp \mathcal{L}_m. \quad (7.1)$$

这样的算法我们称为**斜投影算法**. 如果我们取  $\mathcal{L}_m = \mathcal{K}_m$ , 则上面的算法就是一个**正交投影算法**, 此时条件 (7.1) 称为 **Galerkin 条件**.

设  $v_0, v_1, \dots, v_{m-1}$  和  $w_0, w_1, \dots, w_{m-1}$  分别是  $\mathcal{K}_m$  和  $\mathcal{L}_m$  的一组标准正交基. 令  $V_m = [v_0, v_1, \dots, v_{m-1}]$ ,  $W_m = [w_0, w_1, \dots, w_{m-1}]$ . 则对任意  $\tilde{x} \in \mathcal{K}_m$ , 存在向量  $y \in \mathbb{R}^n$  使得  $\tilde{x} = V_m y$ , 即  $\tilde{x}$  可以由  $v_0, v_1, \dots, v_{m-1}$  线性表出. 根据条件 (7.1), 我们可得

$$(AV_m y - \tilde{\lambda} V_m y, w_i) = 0, \quad i = 1, 2, \dots, m,$$

即

$$W_m^T A V_m y = \tilde{\lambda} W_m^T V_m y. \quad (7.2)$$

这是一个广义特征值问题. 如果我们取  $\mathcal{L}_m = \mathcal{K}_m$ , 并令  $W_m = V_m$ , 则 (7.2) 就化为

$$T_m y = \tilde{\lambda} y, \quad (7.3)$$

其中  $T_m = V_m^T A V_m \in \mathbb{R}^{m \times m}$ . 这意味着  $(\tilde{\lambda}, y)$  是矩阵  $T_m$  的一个特征对. 由于  $m$  通常比较小, 因此我们可以使用先前讨论的方法 (如 QR 迭代) 来计算  $(\tilde{\lambda}, y)$ . 这样我们就可以计算出  $A$  的一个近似特征对  $(\tilde{\lambda}, \tilde{x})$ , 其中  $\tilde{x} = V_m y$ .

## 7.2 Rayleigh-Ritz 算法

事实上, 我们可以在  $\mathcal{K}_m(A, x^{(0)})$  中找出  $m$  个最佳近似特征向量及相应的最佳近似特征值. 这些近似特征值和近似特征向量就是 **Ritz 值** 和 **Ritz 向量**.

**定义 7.1** 设  $\mathcal{K}_m$  是  $\mathbb{R}^{n \times n}$  的一个  $m$  维子空间, 它的一组标准正交基为  $v_0, v_1, \dots, v_{m-1}$ , 并令  $V_m = [v_0, v_1, \dots, v_{m-1}]$ . 记  $T_m = V_m^T A V_m$ , 设  $(\tilde{\lambda}, y)$  是  $T_m$  的一组特征对, 即  $T_m y = \tilde{\lambda} y$  且  $\|y\|_2 = 1$ . 则我们称  $\tilde{\lambda}$  是  $A$  的一个 **Ritz 值**,  $\tilde{x} = V_m y$  是  $A$  的一个 **Ritz 向量**.

**Rayleigh-Ritz 算法** 就是用 Ritz 值和 Ritz 向量来近似  $A$  的特征值与特征向量.

---

### 算法 7.2 Rayleigh Ritz procedure

---

- 1: Compute an orthonormal basis of  $\mathcal{K}$ :  $V_m = [v_0, v_1, \dots, v_{m-1}]$ .
  - 2: Compute the eigenvalues of the matrix  $T_m = V_m^T A V_m$ , i.e., the Ritz values of  $A$ .
  - 3: Select  $k$  desired ones:  $\tilde{\lambda}_1, \tilde{\lambda}_2, \dots, \tilde{\lambda}_k$  where  $k \leq m$ .
  - 4: Compute the eigenvectors  $y_i$  of  $T_m$  associated with  $\tilde{\lambda}_i$ ,  $i = 1, 2, \dots, k$ .
  - 5: Approximate the eigenvectors of  $A$  by the Ritz vectors  $\tilde{x}_i = V_m y_i$ ,  $i = 1, 2, \dots, k$ .
- 

### 7.2.1 对称矩阵

这里我们讨论  $A$  对称时, Rayleigh Ritz 算法的性质.

设  $V_u \in \mathbb{R}^{n \times n-m}$  是一个列正交矩阵, 且使得  $V = [V_m, V_u] \in \mathbb{R}^{n \times n}$  是一个正交矩阵. 于是我们有

$$V^T A V = [V_m, V_u]^T A [V_m, V_u] = \begin{bmatrix} V_m^T A V_m & V_m^T A V_u \\ V_u^T A V_m & V_u^T A V_u \end{bmatrix}.$$

由于  $A$  对称的, 故  $T_m = V_m^T A V_m \in \mathbb{R}^{m \times m}$  也是对称的. 此时, Ritz 值和 Ritz 向量具有下面的最优性质.

**定理 7.1** 设  $A \in \mathbb{R}^{n \times n}$  对称, 则对任意的对称矩阵  $R \in \mathbb{R}^{m \times m}$ , 有

$$\|AV_m - V_m R\|_2 \geq \|AV_m - V_m T_m\|_2,$$

即  $\|AV_m - V_m R\|_2$  在  $R = T_m$  处取最小值, 此时  $\|AV_m - V_m R\|_2 = \|V_u^T A V_m\|_2$ .

**证明.** Let  $R = T_m + Z$  where  $Z \in \mathbb{R}^{m \times m}$  is symmetric. Note that both  $A$  and  $T_m$  are symmetric and  $T_m = V_m^T A V_m$ , we have

$$\begin{aligned} \|AV_m - V_m R\|_2^2 &= (AV_m - V_m R)^T (AV_m - V_m R) \\ &= (AV_m - V_m(T_m + Z))^T (AV_m - V_m(T_m + Z)) \\ &= \|AV_m - V_m T_m\|_2^2 - V_m^T A V_m Z + T_m V_m^T V_m Z \\ &\quad - Z V_m^T A V_m + Z V_m^T V_m T_m + Z^T V_m^T V_m Z \\ &= \|AV_m - V_m T_m\|_2^2 + \|Z\|_2^2. \end{aligned}$$

It follows that  $\|AV_m - V_m R\|_2^2$  is minimized when  $Z = 0$  and

$$\|AV_m - V_m T_m\|_2 = \|V V^T A V_m - V_m T_m\|_2$$

$$\begin{aligned}
&= \left\| (V_m, V_u) \begin{bmatrix} V_m^T A V_m \\ V_u^T A V_m \end{bmatrix} - V_m T_m \right\|_2 \\
&= \|V_u (V_u^T A V_m)\|_2 \\
&= \|V_u^T A V_m\|_2.
\end{aligned}$$

□

注: 定理 7.1 中的 2-范数可以改成任意的酉不变范数, 如  $F$ -范数.

**定理 7.2** 设  $A \in \mathbb{R}^{n \times n}$  对称, 并设  $T_m = U \Lambda U^T$  是  $T_m = V_m^T A V_m$  的特征值分解. 设  $Q \in \mathbb{R}^{n \times m}$  是满足  $\text{span}(Q) = \mathcal{K}$  的任意列正交矩阵,  $D \in \mathbb{R}^{m \times m}$  是任意对角矩阵. 我们有

$$\|AQ - QD\|_2 \geq \|AV_m - V_m T_m\|_2,$$

且当  $Q = V_m U$ ,  $D = \Lambda$  时等式成立.

**证明.** Because  $\text{span}(Q) = \mathcal{K} = \text{span}(V_m)$ , it follows that there exist a matrix  $W \in \mathbb{R}^{m \times m}$  such that  $Q = V_m W$ . As  $Q$  is column orthogonal, we have

$$I = Q^T Q = (V_m W)^T V_m W = W^T V_m^T V_m W = W^T W,$$

which implies that  $W$  is orthogonal. Let  $W D W^T = T_m + Z$ . Then we have

$$\|AQ - QD\|_2^2 = \|AV_m W - V_m W D\|_2^2$$



$$\begin{aligned}
&= \|AV_m - V_m W D W^T\|_2^2 \\
&= \|AV_m - V_m T_m\|_2^2 + \|Z\|_2^2 \\
&\geq \|AV_m - V_m T_m\|_2^2.
\end{aligned}$$

If we choose  $W = U$  and  $D = \Lambda$ , then  $Z = W D W^T - T_m = U \Lambda U^T - T_m = 0$  and, hence, the above equality holds.  $\square$

This result shows that the minimum of  $\|AQ - QD\|_2$  over all  $n$ -by- $k$  column orthogonal matrices  $Q$  with  $\text{span}(Q) = \mathcal{K}$  and over all diagonal matrices  $D$  is attained by  $Q = V_m U$  and  $D = \Lambda$ .

定理 7.1 和定理 7.2 表明, 在  $\|AQ - QD\|_2$  极小的意义下, Ritz 值是特征值的“最佳”近似. 所以我们用 Ritz 值作为特征值的近似是有道理的.

## 7.3 Lanczos 算法

设  $A \in \mathbb{R}^{n \times n}$  是对称矩阵. Lanczos 就是利用 Lanczos 算法来计算  $\mathcal{K}_m$  的基和  $T_m = V_m^T A V_m$ , 然后计算  $A$  的 Ritz 值和 Ritz 向量.

---

### 算法 7.3 Lanczos Algorithm

---

- 1: Choose a vector  $v_0$  such that  $\|v_0\| = 1$ , and set  $\beta_0 = 0$
  - 2: **for**  $j = 0, 1, \dots$  **do**
  - 3:     Compute  $w = Av_j - \beta_j v_{j-1}$
  - 4:      $\alpha_{j+1} = (w, v_j)$
  - 5:      $w = w - \alpha_{j+1} v_j$
  - 6:      $\beta_{j+1} = \|w\|_2$
  - 7:     **if**  $\beta_{j+1} = 0$  **then**
  - 8:         **stop**
  - 9:     **end if**
  - 10:     $v_{j+1} = w / \beta_{j+1}$
  - 11:    Compute the eigenvalues and eigenvectors of  $T_j$
  - 12:    Check the convergence
  - 13: **end for**
-



在 Lanczos 算法 ?? 中, 迭代  $m$  步后, 向量  $v_0, v_1, \dots, v_{m-1}$  构成子空间

$$\mathcal{K}_m(A, v_0) = \text{span} \{v_0, Av_0, \dots, A^{m-1}v_0\},$$

的一组基, 并且有

$$AV_m = V_m T_m + \beta_m v_m e_m^T,$$

其中  $e_m = [0, 0, \dots, 0, 1]^T \in \mathbb{R}^m$ ,

$$T_m = V_m^T A V_m = \begin{bmatrix} \alpha_1 & \beta_1 & & \\ \beta_1 & \ddots & \ddots & \\ & \ddots & \ddots & \beta_{m-1} \\ & & \beta_{m-1} & \alpha_m \end{bmatrix}.$$

设  $(\tilde{\lambda}, y)$  是  $T_m$  的一个特征对, 则有

$$A(V_m y) = V_m T_m y + \beta_m v_m e_m^T y = \tilde{\lambda} V_m y + \beta_m (e_m^T y) v_m.$$

于是

$$Ax - \tilde{\lambda}x = \beta_m (e_m^T y) v_m,$$

即

$$\|Ax - \tilde{\lambda}x\|_2 = |\beta_m (e_m^T y)|,$$

其中  $x = V_m y$ . 如果  $|\beta_m (e_m^T y)|$  很小, 则我们就认为  $\tilde{\lambda}$  是  $A$  的某个特征值的很好的近似. 事实上, 关于 Ritz 值  $\tilde{\lambda}$ , 我们有下面的性质.

**引理 7.1** 设  $A \in \mathbb{R}^{n \times n}$  是对称矩阵, 设  $r = Ax - \tilde{\lambda}x$ , 其中  $x \neq 0$ . 则

$$\min_{\lambda \in \sigma(A)} |\lambda - \tilde{\lambda}| \leq \frac{\|r\|_2}{\|x\|_2},$$

其中  $\sigma(A)$  表示  $A$  的谱, 即所有特征值组成的集合.

**证明.** Let  $A = U\Lambda U^T$  be the eigendecomposition of  $A$ . Then we have

$$r = (A - \tilde{\lambda}I)x = U(\Lambda - \tilde{\lambda}I)U^T x.$$

Denote  $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ . For any vector  $z = [z_1, z_2, \dots, z_n]^T \in \mathbb{R}^n$ , it holds that

$$\begin{aligned} \|(\Lambda - \tilde{\lambda}I)z\|_2^2 &= \sum_{i=1}^n (\lambda_i - \tilde{\lambda})^2 z_i^2 \\ &\geq \sum_{i=1}^n \min_{\lambda \in \sigma(A)} |\lambda - \tilde{\lambda}|^2 z_i^2 \\ &= \|z\|_2^2 \min_{\lambda \in \sigma(A)} |\lambda - \tilde{\lambda}|^2. \end{aligned}$$

Therefore, we have

$$\|r\|_2 = \|U^T r\|_2 = \|(\Lambda - \tilde{\lambda}I)U^T x\|_2 \geq \|U^T x\|_2 \min_{\lambda \in \sigma(A)} |\lambda - \tilde{\lambda}| = \|x\|_2 \cdot \min_{\lambda \in \sigma(A)} |\lambda - \tilde{\lambda}|,$$

which complete the proof. □

由引理 7.1 可知, 存在  $A$  的某个特征值  $\lambda$ , 使得

$$|\lambda - \tilde{\lambda}| \leq \frac{\|\beta_m(e_m^T y)v_m\|_2}{\|V_m y\|_2} = \frac{|\beta_m| \cdot |e_m^T y|}{\|y\|_2} = |\beta_m| \cdot |e_m^T y|. \quad (7.4)$$

**注:** 在前面的讨论中, 我们都没有考虑实际计算时可能的误差. 在实际计算中, 由于浮点运算的误差, 即使  $m$  很小 (如  $m = 10$  或  $m = 20$ ), 也可能导致向量  $\{v_i\}$  失去正交性. 这时我们必须采取一些补救措施, 最简单的方法就是对它们重新来一次正交化, 即在算法 ?? 的第 5 步后加上一条语句

$$w = w - \sum_{i=1}^j (w, v_i) v_i.$$

这个过程就称为带全正交过程的 Lanczos 算法. 显然, 这个过程是非常费时的.

另外一个可行的方法就是选择性正交.

## 7.4 Arnoldi 算法

这里考虑非对称情形, 即计算非对称矩阵  $A$  的特征值. 与 Lanczos 算法的思想相类似, 我们可以使用 Arnoldi 算法, 即通过 Arnoldi 算法计算  $\mathcal{K}_m$  的标准正交基  $v_0, v_1, \dots, v_{m-1}$  和上 Hessenberg 矩阵  $H_m = V_m^T A V_m$ , 使得

$$A V_m = V_m H_m + h_{m+1,m} v_m e_m^T \quad \text{and} \quad V_m^T A V_m = H_m.$$

但此时  $H_m$  只是上 Hessenberg, 而不是对称三对角. 但我们同样可以通过计算  $H_m$  的特征值和特征向量来得到  $A$  的 Ritz 值的 Ritz 向量, 并用它们来近似  $A$  的特征值和特征向量.

设  $(\tilde{\lambda}, y)$  是  $H_m$  的一个特征对, 其中  $\|y\|_2 = 1$ , 则

$$A(V_m y) = V_m H_m y + h_{m+1,m} v_m e_m^T y = \tilde{\lambda} V_m y + h_{m+1,m} (e_m^T y) v_m,$$

所以

$$\|Ax - \tilde{\lambda}x\|_2 = \|h_{m+1,m} (e_m^T y) v_m\|_2 = |h_{m+1,m}| \cdot |e_m^T y|,$$

其中  $x = V_m y$ . 若  $|h_{m+1,m}| \cdot |e_m^T y|$  足够小, 我就认为  $(\tilde{\lambda}, x)$  是  $A$  的某个特征对的近似.

---

### 算法 7.4 Arnoldi Algorithm

---

- 1: Choose a vector  $v_0$  such that  $\|v_0\|_2 = 1$
- 2: **for**  $j = 0, 1, \dots$  **do**
- 3:     Compute  $w_{j+1} = A v_j$

```

4:   for  $i = 0, 1, \dots, j$  do
5:        $h_{ij} = (w_{j+1}, v_i)$ 
6:        $w_{j+1} = w_{j+1} - h_{ij}v_i$ 
7:   end for
8:    $h_{j+1,j} = \|w_{j+1}\|_2$ 
9:   if  $h_{j+1,j} = 0$  then
10:       stop
11:   end if
12:    $v_{j+1} = w_{j+1}/h_{j+1,j}$ 
13:   Compute the eigenvalues and eigenvectors of  $T_j$ 
14:   Check the convergence
15: end for

```

---

由于  $A$  是非对称的, 其特征值可能是复的, 或者是坏条件的, 此时 Lanczos 算法的一些最优性质就不再成立. 尽管如此, 目前还是存在一些有效 Arnoldi 算法的实现方式, 可参见 [22, 28, 29].

## 7.5 非对称 Lanczos 算法

非对称 Lanczos 算法就是 Lanczos 算法在非对称矩阵上的推广,它是基于 Lanczos 双正交化过程.

设  $v_0$  和  $w_0$  是任意的非零向量, 并设

$$\mathcal{K}_m(A, v_0) = \text{span}\{v_0, Av_0, \dots, A^{m-1}v_0\}$$

和

$$\mathcal{K}_m(A^T, w_0) = \text{span}\{w_0, A^T w_0, \dots, (A^T)^{m-1}w_0\}.$$

Lanczos 双正交化过程就是计算  $\mathcal{K}_m(A, v_0)$  和  $\mathcal{K}_m(A, w_0)$  的基  $\{v_i\}$  和  $\{w_i\}$ , 满足  $\{v_i\}$  和  $\{w_i\}$  相互正交, 即

$$(v_i, w_j) = \begin{cases} 0, & i \neq j \\ 1, & i = j \end{cases}.$$

所以

$$W_m^T V_m = I,$$

其中  $V_m = [v_0, v_1, \dots, v_{m-1}]$ ,  $W_m = [w_0, w_1, \dots, w_{m-1}]$ .

注意, 通常  $\{v_i\}_{i=0}^m$  或  $\{w_j\}_{j=0}^m$  本身并不一定正交, 故  $V_m$  和  $W_m$  通常并不列正交.

根据 Lanczos 双正交化过程, 我们可得

$$\begin{aligned} AV_m &= V_m T_m + \gamma_m v_m e_m^T, \\ A^T W_m &= W_m T_m^T + \beta_m w_m e_m^T, \end{aligned}$$

其中  $e_m = [0, \dots, 0, 1]^T \in \mathbb{R}^m$ ,

$$T_m = \begin{bmatrix} \alpha_1 & \beta_1 & & \\ \gamma_1 & \ddots & \ddots & \\ & \ddots & \ddots & \beta_{m-1} \\ & & \gamma_{m-1} & \alpha_m \end{bmatrix}.$$

所以

$$W_m^T A V_m = W_m^T V_m T_m + \gamma_m (W_m^T v_m) e_m^T = T_m.$$

设  $\tilde{\lambda}$  是  $T_m$  的特征值, 其对应的右特征向量和左特征向量分别为  $y$  和  $z$ , 且  $\|y\|_2 = \|z\|_2 = 1$ , 即

$$T_m y = \tilde{\lambda} y \quad \text{and} \quad z^T T_m = \tilde{\lambda} z^T.$$

于是有

$$\begin{aligned} A V_m y &= V_m T_m y + \gamma_m v_m e_m^T y = \tilde{\lambda} V_m y + \gamma_m e_m^T y v_m, \\ (W_m z)^T A &= (A^T W_m z)^T = (W_m T_m^T z)^T + \beta_m e_m^T z w_m^T = \tilde{\lambda} (W_m z)^T + \beta_m e_m^T z w_m^T. \end{aligned}$$

若  $|\gamma_m(e_m^T y)|$  和  $|\beta_m(e_m^T z)|$  足够小, 我们就认为  $\tilde{\lambda}$  是  $A$  的某个特征值的近似, 而  $V_m y$  和  $W_m z$  就是相应的右特征向量和左特征向量的近似.

#### 算法 7.5 Nonsymmetric Lanczos Algorithm

- 1: Choose two vectors  $v_0$  and  $w_0$  such that  $(v_0, w_0) = 1$



```

2: Set  $\beta_0 = 0$  and  $\gamma_0 = 0$ 
3: for  $j = 0, 1, \dots$  do
4:   Compute  $\alpha_{j+1} = (Av_j, w_j)$ 
5:    $\tilde{v}_{j+1} = Av_j - \alpha_{j+1}v_j - \beta_jv_{j-1}$ 
6:    $\tilde{w}_{j+1} = A^T w_j - \alpha_{j+1}w_j - \gamma_jw_{j-1}$ 
7:    $\gamma_{j+1} = |(\tilde{v}_{j+1}, \tilde{w}_{j+1})|^{1/2}$ 
8:   if  $\gamma_{j+1} = 0$  then
9:     stop
10:  end if
11:   $\beta_{j+1} = (\tilde{v}_{j+1}, \tilde{w}_{j+1})/\gamma_{j+1}$ 
12:   $v_{j+1} = \tilde{v}_{j+1}/\gamma_{j+1}$ 
13:   $w_{j+1} = \tilde{w}_{j+1}/\beta_{j+1}$ 
14:  Compute the eigenvalues and eigenvectors of  $T_j$ 
15:  Check the convergence
16: end for

```

---

非对称 Lanczos 算法的显著优点就是节省运算量, 缺点是更容易被中断.

## 参考文献

- [1] J. O. Aasen, On the reduction of a symmetric matrix to tridiagonal form, BIT, 11 (1971), 233–242.
- [2] R. Barrett, et.al, *Templates for the Solution of Linear Systems: Building Blocks for Iterative Methods*, SIAM, 1994. (<http://www.netlib.org/templates/index.html>)
- [3] Åke Björck, Solving linear least square problems by Gram-Schmidt orthogonalization, BIT, 7 (1967), 1–21.
- [4] Åke Björck, *Numerical Methods for Least Squares Problems*, SIAM, Philadelphia, PA, 1996.
- [5] J. J. M. Cuppen, A Divide and Conquer Method for the Symmetric Tridiagonal Eigenproblem, Numerische Mathematik, 36 (1981), 177–195.
- [6] J. W. Demmel, *Applied Numerical Linear Algebra*, SIAM, Philadelphia, PA, 1997.
- [7] Z. Drmač and K. Veselić, New fast and accurate jacobi SVD algorithm. I SIAM Journal on Matrix Analysis and Applications, 29 (2008), 1322–1342.
- [8] Z. Drmač and K. Veselić, New fast and accurate jacobi SVD algorithm. II SIAM Journal on Matrix Analysis and Applications, 29 (2008), 1343–1362.
- [9] K. Fernando and B. Parlett, Accurate singular values and differential qd algorithms, Numerische Mathematik, 67 (1994), 191–229.
- [10] N. Gastinel, *Linear Numerical Analysis*, Kershaw Publishing, London, 1083.
- [11] G. H. Golub, History of numerical linear algebra: A personal view, Stanford, 2007. Available at <http://forum.stanford.edu/events/2007slides/plenary/history-revised-2007-03-19-golub.pdf>
- [12] G. H. Golub and W. Kahan, Calculating the singular values and pseudo-inverse of a matrix, SIAM Journal on Numerical Analysis, Series B, 2 (1965), 205–224.

- [13] G. H. Golub and C. F. Van Loan, *Matrix Computations*, The 4th Edition, The Johns Hopkins University Press, Baltimore, MD, 2013.
- [14] M. Gu and S. C. Eisenstat, A stable algorithm for the rank-1 modification of the symmetric eigenproblem, *SIAM Journal on Matrix Analysis and Applications*, 15 (1994), 1266–1276.
- [15] M. Gu and S. C. Eisenstat, A Divide-and-Conquer algorithm for the bidiagonal SVD, *SIAM Journal on Matrix Analysis and Applications*, 16 (1995), 79–92.
- [16] M. Gu and S. C. Eisenstat, A Divide-and-Conquer algorithm for the symmetric tridiagonal eigenproblem, *SIAM Journal on Matrix Analysis and Applications*, 16 (1995), 172–191.
- [17] A. Hadjidimos, Accelerated overrelaxation method, *Mathematics of Computation*, 32 (1978), 149–157.
- [18] Nicholas J. Higham, *Accuracy and Stability of Numerical Algorithms*, Second Edition, SIAM, Philadelphia, 2002.
- [19] R.A. Horn and C.R. Johnson, *Matrix Analysis*, Cambridge University Press, New York, 1985.
- [20] R.A. Horn and C.R. Johnson, *Topics in Matrix Analysis*, Cambridge University Press, New York, 1991.
- [21] W. Kahan Numerical Linear Algebra, *Canadian Math. Bull.*, 9 (1966), 757–801.
- [22] R. Lehoucq, *Analysis and Implementation of an Implicitly Restarted Arnoldi Iteration*, Ph.D. thesis, Rice University, Houston, TX, 1995.
- [23] E. H. Moore, On the reciprocal of the general algebraic matrix, *Bull. Amer. Math. Soc.*, 26 (1920), 394–395.
- [24] Christopher C. Paige, Miroslav Rozložník and Zdeněk Strakoš, Modified Gram–Schmidt (MGS), least squares, and backward stability of MGS-GMRES, *SIAM Journal on Matrix Analysis and Applications*, (28) 2006, 264–284.
- [25] B.N. Parlett, *The Symmetric Eigenvalue Problem*, The 2nd Edition, SIAM, Philadelphia, PA, 1998.
- [26] R. Penrose, A generalized inverse for matrices, *Proc. Cambridge Philos. Soc.*, 51 (1955), 406–413.

- [27] J. Rutter, *A Serial Implementation of Cuppen's Divide and Conquer Algorithm for the Symmetric Eigenvalue Problem*, Master's Thesis, University of California, 1994.
- [28] Y. Saad, *Numerical Methods for Large Eigenvalue Problems: Theory and Algorithms*, Manchester University Press, Manchester, UK, 1992.
- [29] D. Sorensen, Implicit application of polynomial filters in a  $k$ -step Arnoldi method, *SIAM Journal on Matrix Analysis and Applications*, 13 (1992), 357–385.
- [30] G. W. Stewart, *Matrix Algorithms, Vol I: Basic Decomposition*, SIAM, Philadelphia, PA, 1998.
- [31] G. W. Stewart and Ji-guang Sun, *Matrix Perturbation Theory*, Academic Press, New York, 1990.
- [32] L. N. Trefethen and D. Bau, *Numerical Linear Algebra*, SIAM, Philadelphia, PA, 1997.
- [33] L. N. Trefethen, Numerical Analysis, in *Princeton Companion to Mathematics*, Edited by T. Gowers, J. Barrow-Green and I. Leader, Princeton University Press, 2008.
- [34] D. S. Watkins, *The Matrix Eigenvalue Problem: GR and Krylov Subspace Methods*, SIAM, Philadelphia, 2007.
- [35] D. S. Watkins and L. Elsner, Convergence of algorithms of decomposition type for the eigenvalue problem, *Linear Algebra and its Applications*, 143 (1991), 19–47.
- [36] J.H. Wilkinson, *The Algebraic Eigenvalue Problem*, Clarendon Press, Oxford University, Oxford, 1965.
- [37] R.S. Varga, *Matrix Iterative Analysis*, 2nd edition, Prentice-Hall, Englewood Cliffs, NJ, 2000.
- [38] D.M. Young, *Iterative Solution of Large Linear Systems*, Academic Press, New York, 1971.
- [39] 胡家赣, 线性代数方程组的迭代解法, 科学出版社, 1991.
- [40] 蒋尔雄, 矩阵计算, 科学出版社, 2008.
- [41] 李大明, 数值线性代数, 清华大学出版社.
- [42] 孙继广, 矩阵扰动分析, 科学出版社, 北京, 2001.
- [43] 魏木生, 广义最小二乘问题的理论与计算, 科学出版社, 北京, 2006.
- [44] 徐树方, 矩阵计算的理论与方法, 北京大学出版社, 北京, 1995.